

LAPORAN HASIL DATA ANALYST

Nama Perusahaan : Ford Go Bike
Nama Data Analyst : Desta Aldi Fachri Wibowo
NPM : 10122355 Jenjang/Program
Studi : S1/Sistem Informasi
Tanggal Laporan : 02 Oktober 2025

Laporan Hasil Data Analyst ini Dibuat

Dalam Rangka Bukti Portofolio sebagai Data Analyst

DAFTAR ISI

DAFTAR ISI.....	2
1. PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Tujuan Analisis.....	3
2. IDENTIFIKASI KEBUTUHAN BISNIS.....	4
2.1 Masalah atau Peluang Bisnis yang Ditemukan.....	4
2.2 Pertanyaan Utama Analisis.....	4
3. PENGUMPULAN & PERSIAPAN DATA.....	5
3.1 Sumber Data.....	5
3.2 Proses Praproses.....	5
4. ANALISIS DATA.....	5
4.1 Eksplorasi Variabel Utama.....	5
4.2 Visualisasi Data.....	6
5. TEMUAN & <i>INSIGHT</i>	9
6. PELUANG BISNIS.....	9
7. KESIMPULAN DAN REKOMENDASI.....	10
7.1 Kesimpulan.....	10
7.2 Rekomendasi.....	10
LAMPIRAN-LAMPIRAN.....	11

1. PENDAHULUAN

1.1 Latar Belakang

Dalam layanan bike sharing, analisis data perjalanan merupakan aspek penting untuk memahami pola penggunaan dan kebutuhan operasional. Salah satu tantangan utama adalah distribusi sepeda yang tidak merata di stasiun-stasiun. Stasiun dengan volume perjalanan yang sangat tinggi berpotensi mengalami kekurangan sepeda (bike shortage), sementara stasiun dengan volume rendah dapat menimbulkan pemborosan sumber daya karena kapasitas yang tidak terpakai.

Dataset Ford GoBike Februari 2019 menyediakan data perjalanan dengan atribut detail, termasuk stasiun asal, stasiun tujuan, waktu mulai dan selesai, serta durasi perjalanan. Dengan memanfaatkan data ini, kita dapat melakukan descriptive analytics untuk mengidentifikasi distribusi permintaan pada tiap stasiun.

Analisis ini relevan tidak hanya untuk memberikan gambaran umum tentang penggunaan layanan, tetapi juga sebagai dasar untuk decision support system pada manajemen operasional, misalnya penempatan ulang sepeda (rebalancing), pengaturan kapasitas stasiun, hingga strategi promosi di lokasi tertentu.

1.2 Tujuan Analisis

Proyek analisis data ini memiliki tujuan utama:

1. Mengidentifikasi stasiun dengan volume perjalanan tertinggi dan terendah, baik dari sisi keberangkatan (start station) maupun kedatangan (end station).
2. Menganalisis pola distribusi penggunaan stasiun, sebagai langkah awal memahami keseimbangan permintaan antar lokasi.
3. Menyediakan visualisasi dan metrik deskriptif yang dapat digunakan sebagai dasar rekomendasi operasional dalam pengelolaan layanan bike sharing.

2.IDENTIFIKASI KEBUTUHAN BISNIS

2.1 Masalah atau Peluang Bisnis yang Ditemukan

1. Ketidakseimbangan distribusi sepeda di stasiun

Beberapa stasiun mengalami permintaan tinggi sehingga sepeda cepat habis, sementara stasiun lain sepi sehingga banyak sepeda menganggur. Hal ini dapat menurunkan kepuasan pengguna karena sulit menemukan sepeda di lokasi tertentu atau kesulitan mengembalikannya.

2. Efisiensi operasional

Operator perlu mengoptimalkan logistik pemindahan sepeda antar stasiun (rebalancing) agar tidak membuang terlalu banyak biaya dan waktu. Tanpa data yang jelas, proses ini akan lebih sulit.

3. Kesempatan peningkatan layanan dan ekspansi

Dengan memahami stasiun yang paling ramai dan yang paling jarang digunakan, operator dapat menentukan lokasi strategis untuk promosi, peningkatan kapasitas, atau bahkan pembangunan stasiun baru.

2.2 Pertanyaan Utama Analisis

1. Stasiun mana yang memiliki jumlah keberangkatan (start station) tertinggi dan terendah?
2. Stasiun mana yang memiliki jumlah kedatangan (end station) tertinggi dan terendah?
3. Bagaimana distribusi volume perjalanan di seluruh stasiun (apakah terpusat hanya di beberapa titik atau relatif merata)?

3. PENGUMPULAN & PERSIAPAN DATA

3.1 Sumber Data

Dataset diambil melalui kaggle dengan mengakses link

<https://www.kaggle.com/datasets/nancyalaswad90/trip-data-ford-go-bike>

3.2 Proses Praproses

- Pemeriksaan dan penghapusan data kosong
- Membuat copy dataset
- Cek Outlier
- Standardisasi format kolom (huruf kecil, strip whitespace)
- Deteksi dan penghapusan data duplikat
- Konversi tipe data

4. ANALISIS DATA

4.1 Eksplorasi Variabel Utama


Sebelum mencapai tujuan utama dari analisis data ini, maka diperlukan eksplorasi variabel guna mengetahui pola, kebiasaan dan hal lainnya yang berhubungan dengan tujuan. Variabel yang digunakan untuk dianalisis adalah: 1. Total Perjalanan, 2. Jumlah Stasiun, 3. Distribusi Tipe Pengguna.

Data yang didapat setelah meng-eksplorasi 3 variabel tersebut adalah sebagai berikut:


Jumlah Total Perjalanan	Jumlah Stasiun	Distribusi Tipe Pengguna	
		Subscriber	158.386
174.952	329	User	16.566

4.2 Visualisasi Data



- Memastikan tidak ada data duplikat




- Menampilkan Korelasi antar kolom untuk analisis data



- Menampilkan hasil visualisasi analisis dengan chart yang tepat





5. TEMUAN & INSIGHT

Hasil temuan yang ditemukan dalam data Ford Go Bike adalah:

1. Data tersebut memiliki total 17.318 data kosong yang saling berhubungan tiap kolomnya, seperti ada 197 data kosong pada start_station_id dan start_station_name dan begitupula dengan end_station_id dan end_station_name. Lalu ada 8265 data kosong pada member_birth_year dan juga pada member_gender.
2. Ada 4 data duplikat dan berurutan, mulai dari baris 183412, 183413, 183414, dan 183415.
3. Start_Time dan End_Time tidak ada korelasi langsung secara numerik dengan Duration_Sec, namun distribusi per jam/hari tetap perlu dianalisis karena bisa mempengaruhi demand.
4. Acuan waktu hanya berpusat pada Duration_Sec.

Insight yang didapat:

1. **San Francisco Ferry Building** menjadi tujuan awal ataupun akhir **Tertinggi** bagi para pengguna Ford Go Bike, baik subscriber ataupun user biasa, disusul dengan **Market st at 10th st**.
2. **16th st depot** dan **palm st at willow st** menjadi stasiun keberangkatan **Terendah**

6. PELUANG BISNIS

Peluang bisnis yang dapat dipertimbangkan adalah:

1. Optimalisasi infrastruktur pada stasiun yang paling ramai ataupun yang paling sepi.
2. Dapat menyediakan iklan ataupun kegiatan komersil pada stasiun yang paling ramai dikunjungi.
3. Menambah jumlah pasokan sepeda pada stasiun yang ramai dikunjungi.

7.KESIMPULAN DAN REKOMENDASI

7.1 Kesimpulan

Analisis data Ford GoBike Februari 2019 menunjukkan adanya kendala kualitas data berupa nilai kosong yang cukup banyak pada kolom stasiun dan atribut demografis, serta beberapa data duplikat yang telah dibersihkan. Variabel durasi perjalanan (*duration_sec*) terbukti menjadi indikator utama perilaku pengguna, sementara start time dan end time lebih relevan untuk melihat pola jam dan hari penggunaan. Dari sisi penggunaan, San Francisco Ferry Building muncul sebagai stasiun paling ramai baik untuk keberangkatan maupun tujuan, disusul Market St at 10th St, sedangkan 16th St Depot dan Palm St at Willow St relatif sepi digunakan. Sebagian besar perjalanan berdurasi singkat di bawah lima belas menit, selaras dengan karakteristik layanan bike-sharing.

7.2 Rekomendasi

Berdasarkan temuan tersebut, disarankan agar Ford GoBike meningkatkan kapasitas di stasiun dengan permintaan tinggi sekaligus mengevaluasi efektivitas stasiun dengan aktivitas rendah. Strategi redistribusi sepeda perlu diperkuat untuk menjaga keseimbangan supply pada jam sibuk. Dari sisi bisnis, perusahaan dapat mengembangkan paket khusus bagi pengguna berlangganan yang dominan di rute komuter, serta promosi berbasis rekreasi untuk pengguna kasual, terutama di akhir pekan. Pengayaan data demografis serta potensi kemitraan dengan bisnis lokal di sekitar stasiun populer juga dapat membuka peluang untuk meningkatkan nilai layanan sekaligus memperluas jangkauan pasar.

LAMPIRAN-LAMPIRAN

```
import pandas as pd
import kagglehub
from kagglehub import KaggleDatasetAdapter
import seaborn as sns
import matplotlib.pyplot as plt

# Mengambil file dari kaggle
file_path = "fordgobike-tripdataFor201902.csv"
df = kagglehub.load_dataset(
    KaggleDatasetAdapter.PANDAS,
    "nancyalaswad90/trip-data-ford-go-bike",
    file_path,
)

print("First 5 records:", df.head()) # Melihat data

#Mengecek Kolom Kosong
df.isnull().sum()

# Membuat Copy Data
df_copy = df.copy()

# Melakukan Pembersihan Data Kosong dengan Menggunakan Data Copy
df_clean =
df_copy.dropna(subset=['start_station_id', 'start_station_name', 'end_station_id', 'end_station_name', 'member_birth_year', 'member_gender'])

df_clean.isnull().sum()

# Melihat Outliers
df_clean['duration_sec'].describe()
Q1 = df_clean['duration_sec'].quantile(0.25)
Q3 = df_clean['duration_sec'].quantile(0.75)
IQR = Q3 - Q1

outliers = df_clean[(df_clean['duration_sec'] < Q1 - 1.5*IQR) |
(df_clean['duration_sec'] > Q3 + 1.5*IQR)]
print(outliers)
sns.boxplot(x=df['duration_sec'])
plt.show()

# Merapikan Nama Kolom
df_clean.columns = df_clean.columns.str.lower().str.replace(' ', '_')
```

```

# Mengubah Tipe Data Tiap Kolom
df_clean['start_station_id'] = df_clean['start_station_id'].astype('int64')
df_clean['end_station_id'] = df_clean['end_station_id'].astype('int64')
df_clean['bike_id'] = df_clean['bike_id'].astype('int64')
df_clean['user_type'] = df_clean['user_type'].astype('category')
df_clean['member_birth_year'] = df_clean['member_birth_year'].astype('int64')
df_clean['member_gender'] = df_clean['member_gender'].astype('category')

# Membersihkan data duplikat
df_clean = df_clean.drop_duplicates()
df_clean.duplicated().sum()

# Standarisasi Data
# Hapus spasi
df_clean = df_clean.applymap(lambda x: x.strip() if isinstance(x, str) else x)

# Ubah semua string jadi lowercase
df_clean = df_clean.applymap(lambda x: x.lower() if isinstance(x, str) else x)

# Melihat jumlah data
print("Jumlah total perjalanan:", len(df_clean))
print("Jumlah stasiun asal unik:", df_clean['start_station_name'].nunique())
print("Jumlah stasiun tujuan unik:", df_clean['end_station_name'].nunique())
print("\nDeskripsi durasi perjalanan (detik):")
print(df_clean['duration_sec'].describe())
print("\nDistribusi user type:")
print(df_clean['user_type'].value_counts())

```